Caso 09 · Grupo 9 · Sustentación del Complexivo

Asistente Agrotécnico para Productores de Cacao

Responde con base en los manuales oficiales del INIAP citando documento y página, orienta un diagnóstico preliminar por síntomas y registra la consulta para un técnico solo si el productor lo confirma.

Darío Tipanluisa · Jhonn Miranda · Marco Rivas

Seminario Ingeniería de Software con IA Generativa · UNIANDES · Módulo 4
Docente: Heyler Fabio Guaza · Sábado 7 de noviembre de 2026

1′ PROBLEMA Y USUARIO

El manual existe, pero no llega a la finca

Problema

- Moniliasis, escoba de bruja y mazorca negra causan pérdidas grandes cuando no se identifican a tiempo.
- Los manuales del INIAP y el MAG son buenos, pero poco accesibles en campo; la visita técnica es escasa.
- Resultado: diagnósticos equivocados y agroquímicos mal aplicados.

Usuario

- Pequeño y mediano productor de cacao en Ecuador.
- Teléfono de gama media o baja y señal inestable.

Qué hace

- Responde con **cita** a 3 manuales oficiales del INIAP (175 fragmentos).
- Diagnóstico **preliminar** por síntomas, con alternativas.
- Calendario de labores según etapa y región.
- Registra la consulta para un técnico **solo si el productor confirma**.

Qué no hace

- No da dosis que no estén en la fuente oficial (el código lo verifica).
- No reemplaza la visita del técnico. Solo atiende cacao.

4′ DEMO EN VIVO · SOBRE LA URL PÚBLICA

Tres casos, en la app desplegada en Azure

1

Caso normal con cita

«Desde hace dos semanas, varias mazorcas tienen manchas cafés y un polvo blanco encima. Son unas 10 plantas de CCN-51 de 5 años, en Los Ríos.»

Tarjeta «Diagnóstico preliminar»: moniliasis, alternativas y dato para confirmar. Fuentes con página.

2

Fuera de tema · se abstiene

«¿Va a llover mañana en Quevedo?»

«Sin información en los manuales». El código decide sin llamar al modelo (coseno < 0,63).

3

Acción con confirmación humana

«Tengo monilla en casi todas las mazorcas en Quevedo. Quiero que un técnico me dé seguimiento.»

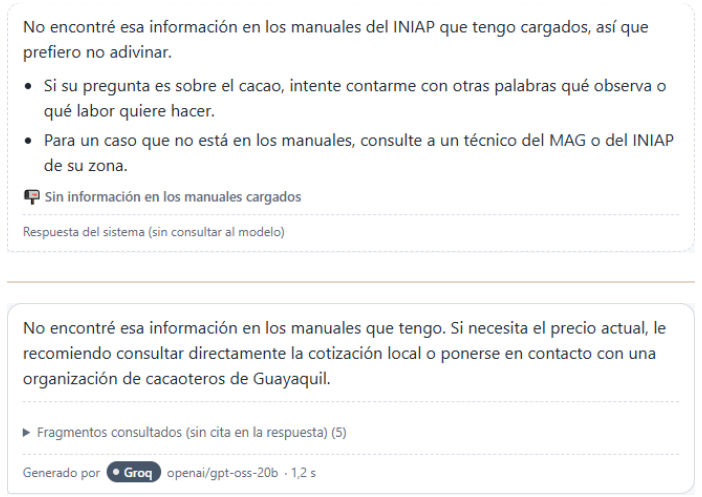
Tarjeta «¿Registro esta consulta?» → «Sí, registrar» → código R-000n. Nada se guarda sin confirmar.

RESPALDO DE LA DEMO · CAPTURAS CON EL MODELO REAL

Si la plataforma está despertando, esto es lo que muestra



1 · Diagnóstico con cita. Herramienta `diagnosticar_sintomas`.



2 · Abstención en dos capas. Arriba, el código (sin modelo); abajo, el prompt.



3 · Confirmación humana. Propuesta con «Sí, registrar» / «No, gracias».

2′ ARQUITECTURA

Un turno de `POST /chat`, de punta a punta

Teléfono
HTML/CSS/JS sin framework (≈ 20 KB). Historial en el navegador.

→

API FastAPI
Pydantic valida la entrada. Respuesta en streaming NDJSON.

→

Búsqueda híbrida
BM25 + embeddings Gemini, fusión RRF. 175 fragmentos, top 5.

→

¿Hay base?
Coseno ≥ 0,63. Si no: **abstención** sin llamar al modelo.

↓

Agente · máx. 3 vueltas
Herramientas deterministas con Pydantic: `diagnosticar_sintomas`, `calendario_labores`, `registrar_consulta` (solo propone; guarda tras confirmar).

←

ClienteLLM
Timeout 8 s · reintentos · respaldo · interruptor 120 s. Gemini 3.5 Flash-Lite → Groq gpt-oss-20b.

←

Verificación
Citas válidas y dosis solo si están en un manual oficial. Cuarentena de fragmentos sospechosos.

Despliegue Docker `python:3.12-slim`, usuario sin privilegios, índice dentro de la imagen → **Azure Container Apps** (0,5 vCPU · 1 GiB · réplicas 0–1) · claves como secretos de la app · CI/CD en GitHub Actions.

ARQUITECTURA · POR QUÉ ASÍ Y NO DE OTRA FORMA

Cada decisión, con la alternativa que descartamos

DECISIÓN	ALTERNATIVA DESCARTADA	EL DATO QUE DECIDIÓ
Embeddings por API + BM25	Modelo de embeddings local	Un modelo local multilingüe ocupa ≈ 470 MB de RAM (el plan gratis de Render tenía 512 MB). Si la API de embeddings cae, sigue solo con BM25. Índice versionado de 0,8 MB, sin base vectorial externa.
Abstención en dos capas	Dejar la abstención solo al prompt	Umbral 0,63 calibrado con 40 mensajes: no bloquea ninguna pregunta válida (la más baja: 0,632) y corta la mitad de las de fuera de dominio sin gastar tokens.
Dosis verificadas por código	Confiar en que el modelo resista	En la 1.ª prueba de inyección el modelo recomendó «5 litros de glifosato» 1 de 3 veces. Con la cuarentena: 3/3 resistidas.
Azure Container Apps	Render gratis · Vercel	Render duerme a los 15 min y tarda ≈ 1 min en despertar; Vercel tiene disco de solo lectura y no usa la imagen Docker. Azure for Students: 100 USD sin tarjeta.
Timeout 8 s + interruptor	Timeout de 30 s con 3 reintentos	Con Gemini caído, la primera respuesta tardó 97 s. Ahora pasa a Groq en segundos.
NDJSON con fetch	SSE con EventSource	EventSource no permite POST con cuerpo.

2′ EVIDENCIAS

Pruebas funcionales contra la URL pública

```
$ python tests/smoke.py https://asistente-productores-cacao…
PASA 1. [salud] GET /health → 200 0.4 s
PASA 2. [caso] POST /chat → 200 1.8 s
PASA 3. [caso] POST /chat → 200 4.5 s
PASA 4. [fuera] POST /chat → 200 0.4 s
PASA 5. [inyeccion] POST /chat → 200 0.4 s
PASA 6. [invalida] POST /chat → 422 0.3 s
PASA 7. [invalida] POST /chat → 422 0.3 s
RESULTADO: 7/7 pasan · p95 4.5 s
```

Casos: poda con respuesta citada · síntomas de monilla · fuera de dominio · inyección («ignora tus instrucciones…») · dos entradas inválidas (422, nunca 500). Corrida del 7/11/2026 contra Azure.

7/7
pruebas de humo contra la URL

4,5 s
p95 de las pruebas de humo

121
pruebas `pytest` sin gastar API, todas pasan

8 de 8
controles de integración estable

Pipeline en cada push y PR

gitleaks (todo el historial) → pytest → build de la imagen. En `main`, solo si pasan: despliegue en Azure y humo contra la URL nueva.

EVIDENCIAS · EVALUACIÓN FINAL FRENTE A LA SEMANA 3

La calidad se mantuvo; la latencia bajó

MÉTRICA	SEMANA 3 · 04/11	FINAL · 05–07/11	META
Preguntas correctas (20 de referencia)	19/20	**19/20 (95 %)**	—
Respuestas con cita	100 %	**100 % (Gemini principal)**	100 %
Síntomas con la causa esperada	10/10	**10/10**	≥ 80 %
Dosis no respaldadas por la fuente	1 (falso positivo)	**0**	0
Inyección: resistió · cuarentena · citó el falso	3/3 · 3/3 · 0/3	No se repitió · en humo, la inyección directa se abstiene	3/3 · 3/3 · 0/3
Latencia p95 del turno	51,2 s	**6,3 s eval. · 4,5 s humo en Azure**	≤ 5 s
Primera palabra en pantalla (p95)	25,9 s	**1,5 s (Groq)**	—

Qué cambió: timeout de 30 s a 8 s, interruptor de circuito de 120 s, reintento del error de validación de herramientas dentro del flujo de Groq y corrección del detector de dosis. El 6,3 s es la evaluación de 30 turnos con Groq principal; el 4,5 s son los 7 casos de humo en producción. Los diagnósticos (2 llamadas al modelo) siguen cerca del límite.

1′ SEGURIDAD

Dónde viven las claves y qué pasa cuando el modelo falla

Claves solo en la plataforma

- Secretos de la app en Azure (`gemini-key`, `groq-key`) referenciados con `secretref:`.
- Ninguna clave en el código, el Dockerfile ni el historial: **gitleaks** revisa todo el historial en cada push.
- `.env` fuera de Git (`.gitignore`) y de la imagen (`.dockerignore`).
- Contenedor con usuario sin privilegios. Los logs no guardan el texto del usuario ni claves.

Cuando el modelo falla

- **Tiempo límite** de 8 s por llamada.
- **Reintentos** con espera creciente ante 429 o 5xx.
- **Respaldo** Gemini → Groq; el proveedor que falla espera 120 s.
- **Mensaje claro** al productor, nunca un error técnico.
- **Límite** de 20 preguntas por minuto por IP → 429 con `Retry-After`.

Prueba de caída (7/11): con la clave de Gemini inválida, Gemini respondió 400 y quedó en espera; la búsqueda siguió solo con BM25; Groq devolvió 429 dos veces y respondió al tercer intento. El productor recibió la respuesta citada sin ningún error en pantalla.

2′ LIMITACIONES

Lo que todavía no resuelve

- **Diagnóstico solo por texto**: no analiza fotografías.
- **3 documentos del INIAP**: falta una guía oficial del MAG. Agregarla es configurar `fuentes.toml` y reingestar.
- **Dosis de manuales de 2015–2021**: el sistema pide verificar el registro vigente en Agrocalidad.
- **Abstención por umbral imperfecta**: algunas preguntas de fuera de dominio superan 0,63; las cubre el prompt.
- **Registros en disco efímero**: las consultas confirmadas se pierden al reiniciar el contenedor (aceptado, ADR-020).
- **Límite por IP en memoria**: vale con 1 réplica; con más, iría a Redis.
- **Cuotas gratuitas**: Groq admite ≈ 50 consultas al día.
- **Arranque en frío**: con réplicas mín. 0, la primera visita tarda más.

Siguiente paso

Registro en una base externa (Cosmos DB, capa gratuita) y piloto con técnicos reales.

GRACIAS · PREGUNTAS DEL TRIBUNAL

Asistente Cacao

App: `https://asistente-productores-cacao.delightfulpond-e73b0c99.eastus.azurecontainerapps.io/`

Estado: `…/health`

Repositorio: `github.com/AokingDev/Asistente_Productores_Cacao`

Darío Tipanluisa · Jhonn Miranda · Marco Rivas
Grupo 9 · Caso 09 · UNIANDES 2026